



UNIVERSIDAD NACIONAL AGRARIA

**LA MOLINA**

## Maestría en Estadística Aplicada

### Técnicas de análisis de series de tiempo Modelos de Box Jenkins

Mg. Jesús Eduardo Gamboa Unsihuay

21 de mayo de 2019

# Estructura del capítulo IV

1. Introducción
2. Modelo autorregresivo (AR)
3. Modelo de medias móviles (MA)
4. Modelo ARMA
5. Modelo ARIMA
6. Modelo SARIMA

# Introducción

- Describen y pronostican series de tiempo **estacionarias**.
- Por practicidad, vamos a asumir teóricamente modelos estacionarios en  $\mu = 0$ , o que las observaciones están centradas.
- Suelen ser parsimoniosos (respecto a los modelos estudiados previamente).
- Es recomendable tener experiencia y conocimiento de los datos.
- No puede ser modelado “manualmente”, requiere de *software*.

# Operadores

## Operador retardo

Considere la serie de tiempo  $Y_1, \dots, Y_n$ , entonces el operador retardo B (*back*), a veces también denominado L (*lag*), se define como:

$$BY_t = Y_{t-1}$$

de manera general:

$$B^m Y_t = Y_{t-m}$$

para  $t = m, m + 1, \dots, n$

# Operadores

## Operador adelanto

Considere la serie de tiempo  $Y_1, \dots, Y_n$ , entonces el operador adelanto  $F$  (*future*) se define como:

$$FY_t = Y_{t+1}$$

de manera general:

$$F^m Y_t = Y_{t+m}$$

para  $t = 1, \dots, n - m$

# Operadores

## Operador diferencia

Considere la serie de tiempo  $Y_1, \dots, Y_n$ , entonces el operador diferencia  $\Delta$  se define como:

$$\Delta Y_t = Y_t - Y_{t-1} = Y_t - BY_t = (1 - B)Y_t$$

para  $t = 2, \dots, n$ . Entonces:

$$\Delta = 1 - B$$

Además:

$$(\Delta)^2 Y_t = \Delta Y_t - \Delta Y_{t-1} = (Y_t - Y_{t-1}) - (Y_{t-1} - Y_{t-2})$$

En general:

$$(\Delta)^n Y_t = (\Delta)^{n-1} Y_t - (\Delta)^{n-1} Y_{t-1}$$

La diferenciación permite eliminar la tendencia de una serie de tiempo.

# Operadores

## Integración

Considere la serie de tiempo  $Y_1, \dots, Y_n$ , se dice que es integrada de orden  $d$ ,  $I(d)$ , si la  $d$ -ésima diferencia de  $Y_t$  es un ruido blanco:

$$(\Delta)^d y_t = \epsilon_t$$

$$(1 - B)^d y_t = \epsilon_t$$

Lo más común es emplear, como máximo,  $d = 2$ .

# Función de autocorrelación

- Mide la relación lineal entre las observaciones de la serie temporal separadas por un desfase de  $k$  unidades de tiempo:

$$\rho_k = \text{Corr}(X_t, X_{t-k})$$

- Puede truncarse o puede extinguirse. Este comportamiento sirve para identificar un modelo tentativo.
- Se **trunca** cuando la última autocorrelación significativa es grande y las restantes son significativamente iguales a cero. Un truncamiento rápido es indicador de estacionariedad.
- Se **extingue** cuando decrece de forma permanente (lenta).



# Función de autocorrelación

“Al seleccionar un modelo, recuerde que las distribuciones que se muestran son teóricas y que es muy improbable que las autocorrelaciones de datos reales sea idénticas exactamente a cualquiera de las distribuciones teóricas. Sin embargo, usted debe, mediante prueba y error, poder ubicar en forma adecuada la mayoría de series de tiempo de datos, y al ganar experiencia, la tarea se hará más fácil (Hanke y Reitsch, 1996)”

# Función de autocorrelación parcial

- Es la correlación resultante entre valores de la serie que están desfasados  $k$  periodos, que no es explicada por los retrasos de orden 1 a  $k - 1$  (aislando el efecto de dichos retrasos). Puede entenderse como una correlación condicional:

$$\rho_{k,k} = \text{Corr}(X_t, X_{t+k} | X_{t+1}, X_{t+2}, \dots, X_{t+k-1})$$

De ahí que  $\rho_1 = \rho_{1,1}$

- Es análogo al coeficiente  $\beta$  es un modelo de regresión lineal.
- Coincide con el  $k$ -ésimo término de un modelo Autorregresivo de orden  $k$ , es decir AR( $k$ ).
- También puede truncarse o extinguirse. Este comportamiento sirve para identificar un modelo tentativo.

# Pruebas de estacionariedad

## Prueba KPSS

- Fue propuesta por Kwiatkowski, Phillips, Schmidt y Shin en 1992 a fin de probar la estacionariedad de una serie de tiempo.
- Prueba principalmente si la serie es estacionaria en media ( $H_0$ ) o no lo es ( $H_1$ ).
- También permite evaluar si una serie presenta tendencia estacionaria (determinística) o no.
- En R puede ser obtenida con la función `kpss.test` del paquete `tseries`.

# Pruebas de estacionariedad

## Prueba Dickey - Fuller de raíces unitarias

- Fue propuesta por David Dickey y Wayne Fuller (1979). Si establecemos el modelo:

$$Y_t = \rho Y_{t-1} + \epsilon_t$$

- Se dice que tiene una raíz unitaria si  $\rho = 1$ . De ser ese el caso, la serie no sería estacionaria. Entonces si una serie presenta raíz unitaria, no es estacionaria.
- La prueba de Dickey Fuller contrasta las hipótesis:  
 $H_0$  : Existe raíz unitaria en la serie (la serie no es estacionaria)  
 $H_1$  : No existe raíz unitaria en la serie (la serie es estacionaria)
- En R se puede usar las funciones `adf.test` (en el paquete `tseries`) y `ur.df` (en el paquete `urca`)

# Pruebas de estacionariedad

## Prueba Dickey - Fuller Aumentada de raíces unitarias

Ajustando un modelo autorregresivo de desfase  $k$ , esta prueba examina la hipótesis nula de un  $ARIMA(p, 1, 0)$  versus el proceso estacionario  $ARIMA(p + 1, 0, 0)$ , para valores de  $p \leq k - 1$ . Se usan las mismas funciones que Dickey Fuller, incrementando el argumento lag.

# Pruebas de estacionariedad

## Prueba Phillips-Perron de raíces unitarias

Propuesta por Peter Phillips y Pierre Perron en 1988. Trabaja de manera similar a la prueba de Dickey Fuller. Estas pruebas serán muy importantes en la fase de identificación del modelo

# Fases del modelamiento

## 1 Identificación

- Determinar el modelo tentativo
- Determinar el orden tentativo

## 2 Estimación

- Uso de *software*. Mínimos cuadrados no lineal (método iterativo)

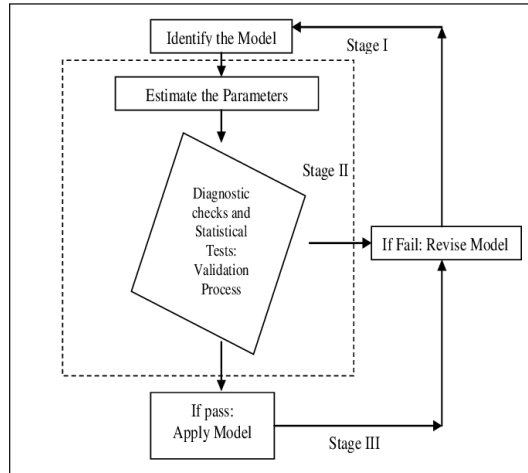
## 3 Diagnóstico

- Agregar más rezagos: ¿son significativos?
- Análisis de residuos: media cero, no autocorrelación, evaluación de indicadores (MSE, MAPE, ...)
- Validación cruzada
- De ser necesario, se puede volver al paso de identificación.

## 4 Predicción

- Aplicar el modelo elegido para realizar pronósticos de horizonte  $h$  a partir del tiempo  $n$ .

# Fases del modelamiento





# Modelo AR(p)

- El modelo autorregresivo de orden  $p$  se define como:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

$$Y_t = \phi_1 B Y_t + \phi_2 B^2 Y_t + \dots + \phi_p B^p Y_t + \epsilon_t$$

$$\epsilon_t = Y_t - \phi_1 B Y_t - \phi_2 B^2 Y_t - \dots - \phi_p B^p Y_t$$

$$\epsilon_t = Y_t(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)$$

$$\epsilon_t = \phi(B) Y_t$$

donde  $\phi(B)$  es conocido como polinomio autorregresivo y  $\epsilon_t \sim N(0, \sigma_e^2)$

- Un modelo de suavización exponencial simple es un  $AR(\infty)$  con  $\phi_i = \alpha(1 - \alpha)^i$  para  $i = 1, 2, \dots$
- Un paseo aleatorio es un  $AR(1)$  con  $\phi_1 = 1$ .

# Modelo AR(1)

- El modelo autorregresivo de orden 1 se define como:

$$Y_t = \phi_1 Y_{t-1} + \epsilon_t$$

$$\epsilon_t = \phi(B)Y_t$$

donde  $\phi(B) = 1 - \phi B$  es el polinomio autorregresivo. Este polinomio sirve en la evaluación de la estacionariedad del modelo.

# Propiedades del modelo AR(1)

- El modelo AR(1) estacionario si  $|\phi| < 1$ :  
La raíz de B debe ser mayor que la unidad (caer fuera del círculo unitario), es decir  $|B| > 1$ , lo que equivale a decir  $\left|\frac{1}{\phi}\right| > 1$ , en consecuencia  $|\phi| < 1$
- El modelo AR(1) siempre es invertible (puede expresarse como un modelo MA):

$$Y_t = \phi Y_{t-1} + \epsilon_t$$

$$Y_t = \phi(\phi Y_{t-2} + \epsilon_{t-1}) + \epsilon_t$$

...

$$Y_t = \epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots$$

# Parámetros del modelo AR(1)

## Funciones media y varianza

- Función media: dado que el proceso es estacionario:

$$E(Y_t) = E(\phi Y_{t-1} + \epsilon_t)$$

$$E(Y_t) = \phi E(Y_t)$$

$$(1 - \phi)E(Y_t) = 0 \rightarrow E(Y_t) = 0$$

con la restricción de que  $(1 - \phi) \neq 0$ , es decir  $\phi \neq 1$

- Función varianza: puede demostrarse que :

$$V(Y_t) = \gamma_0 = \frac{\sigma_e^2}{1 - \phi^2}$$

donde  $|\phi| < 1$ .

# Parámetros del modelo AR(1)

## Funciones de autocovarianza y autocorrelación

- Función de autocovarianza:

$$\gamma_k = \begin{cases} \frac{\sigma_e^2}{1-\phi^2} & k=0 \\ \phi\gamma_{k-1} & k=1,2,3,\dots \end{cases}$$

- Función de autocorrelación: se extingue de manera exponencial y amortiguada .

$$\rho_k = \phi^k$$

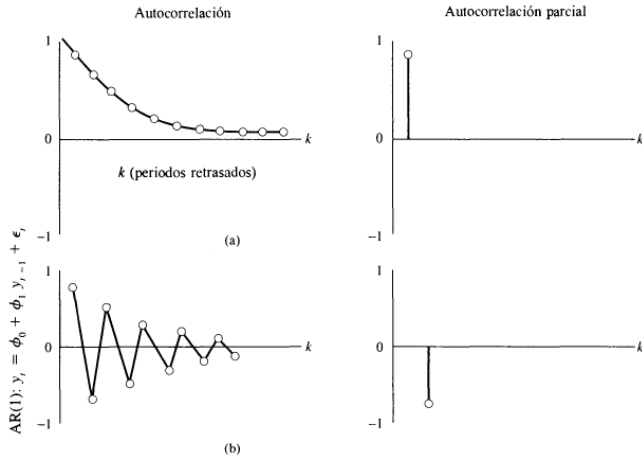
para  $k = 0, 1, 2, 3, \dots$

- Función de autocorrelación parcial: se trunca luego del orden  $k = 1$ .

$$\rho_{k,k} \begin{cases} \neq 0 & k=1 \\ = 0 & k=2,3,\dots \end{cases}$$

# Parámetros del modelo AR(1)

## Autocovarianza y autocorrelación



# Simulación de un modelo AR(1)

Código en 

Para simular un AR(1):

```
arima.sim(model=list(ar=c(phi)), n = muestra, sd = sigma)
arima.sim(model=list(order=c(1,0,0),ar=c(phi)), n = muestra, sd = sigma)
```

donde:

- $\phi$  es el parámetro del modelo AR(1).
- *muestra* es el tamaño de muestra a ser simulado.
- *sigma* es la desviación del ruido blanco, es decir  $\sigma_e$ .

# Modelo AR(2)

- El modelo autorregresivo de orden 2 se define como:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t$$

$$\epsilon_t = \phi(B)Y_t$$

donde  $\phi(B) = 1 - \phi_1 B - \phi_2 B^2$  es el polinomio autorregresivo.



# Propiedades del modelo AR(2)

- El modelo AR(2) estacionario si se cumplen al mismo tiempo las 3 siguientes condiciones:  $\phi_1 + \phi_2 < 1$ ,  $-\phi_1 + \phi_2 < 1$  y  $|\phi_2| < 1$ :
- El modelo AR(2) siempre es invertible (puede expresarse como un modelo MA).

# Parámetros del modelo AR(2)

## Funciones media y varianza

- Función media:

$$E(Y_t) = E(\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t)$$

Bajo las condiciones de estacionariedad que serán impuestas más adelante:

$$E(Y_t) = 0$$

- Función varianza: puede demostrarse que :

$$V(Y_t) = \gamma_0 = \frac{\sigma_e^2}{1 - \phi_1 - \phi_2}$$

donde  $\phi_1$  y  $\phi_2$  siguen las condiciones de estacionariedad que serán impuestas más adelante.

# Parámetros del modelo AR(2)

## Funciones de autocovarianza y autocorrelación

- Función de autocovarianza, para  $k > 0$ :

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}$$

- Función de autocorrelación: para  $t > 0$ :

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

- Función de autocorrelación parcial: se trunca luego del orden  $k = 2$ .

$$\rho_{kk} \begin{cases} \neq 0 & sik=1, 2 \\ = 0 & sik=3, 4, \dots \end{cases}$$

# Simulación de un modelo AR(2)

Código en 

Para simular un AR(2):

```
arima.sim(model=list(ar=c(phi1,phi2)), n = muestra, sd = sigma)
```

```
arima.sim(model=list(order=c(2,0,0),ar=c(phi1,phi2)), n = muestra, sd = sigma)
```

donde:

- $\phi_1$  y  $\phi_2$  son los parámetros del modelo AR(2).
- `muestra` es el tamaño de muestra a ser simulado.
- `sigma` es la desviación del ruido blanco, es decir  $\sigma_e$ .

# Modelo AR(p)

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

- Función media

$$\mu = 0$$

- Función varianza

$$\gamma_0 = \phi_1 \gamma_1 + \dots + \phi_p \gamma_p + \sigma_e^2$$

- Función de autocovarianza

$$\gamma_k = \phi_1 \gamma_{k-1} + \dots + \phi_p \gamma_{k-p} \quad k > 0$$

- Función de autocorrelación

$$\rho_k = \phi_1 \rho_{k-1} + \dots + \phi_p \rho_{k-p} \quad k > 0$$

- Función de autocorrelación parcial:

$$\rho_{kk} = 0 \quad k > p$$

# Modelo MA(q)

- El modelo de medias móviles de orden  $q$  se define como:


$$Y_t = \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \dots - \theta_q \epsilon_{t-q}$$

$$Y_t = \epsilon_t - \theta_1 B \epsilon_t - \theta_2 B^2 \epsilon_t - \dots - \theta_q B^q \epsilon_t$$

$$Y_t = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) \epsilon_t$$

$$Y_t = \theta(B) \epsilon_t$$

donde  $\theta(B)$  es conocido como polinomio de medias móviles y  $\epsilon_t \sim N(0, \sigma_e^2)$

- Media móvil ponderada de ruidos blancos.
- No es tan intuitivo como un modelo AR(p) pero es útil.
- Importante: En  el modelo MA(q) es especificado como:

$$X[t] = e[t] + b[1]e[t-1] + \dots + b[q]e[t-q]$$

Es decir:

$$\theta_j^* = -\theta_j$$

donde  $\theta_j^* = b[j]$

# Modelo MA(1)

- El modelo de medias móviles de orden 1 se define como:

$$Y_t = \epsilon_t - \theta\epsilon_{t-1}$$

$$Y_t = \theta(B)\epsilon_t$$

donde  $\theta(B) = 1 - \theta B$  es el polinomio de medias móviles.

# Parámetros del modelo MA(1)

Media, varianza y autocovarianza

- Función media:

$$E(Y_t) = E(\epsilon_t - \theta\epsilon_{t-1}) = 0$$

- Función varianza: puede demostrarse que:

$$V(Y_t) = \gamma_0 = (1 + \theta^2)\sigma_e^2$$

- Función de autocovarianza: distinta de cero para  $k = 1$ :

$$\gamma_k = \begin{cases} -\theta\sigma_e^2 & \text{si } k=1 \\ 0 & \text{si } k=2,3,\dots \end{cases}$$



# Parámetros del modelo MA(1)

## Autocorrelación y autocovarianza

- Función de autocorrelación:

$$\rho_k = \begin{cases} \frac{-\theta}{1+\theta^2} & k=1 \\ 0 & k=2,3,\dots \end{cases}$$

- Función de autocorrelación parcial:  $\rho_{kk}$  se extingue de manera exponencial amortiguada.

# Parámetros del modelo MA(1)

## Autocovarianza y autocorrelación

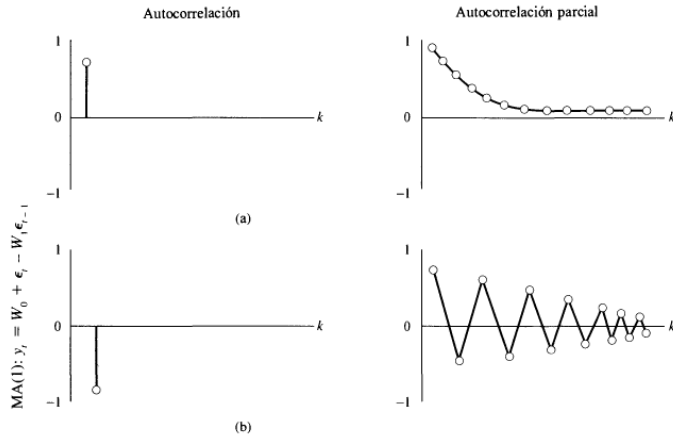


Figura: Fuente: Hanke y Reitsch

# Parámetros del modelo MA(1)

## Autocovarianza y autocorrelación

- Teóricamente no existen en simultáneo:

$$\gamma_k \begin{cases} \neq 0 & sik=1,2,\dots,p \\ = 0 & sik=p+1, p+2, \dots \end{cases}$$

$$\rho_k \begin{cases} \neq 0 & sik=1,2,\dots,p \\ = 0 & sik=p+1, p+2, \dots \end{cases}$$

- Sin embargo pueden darse muestralmente.
- Evaluar entre AR(1) y MA(1):
  - ¿cuál se corta de manera más abrupta?
  - Contribución significativa
  - Indicadores (RMSE, MAPE, etc)
  - AIC

# Simulación de un modelo MA(1)

Código en 

Para simular un MA(1):

```
arima.sim(model=list(ma=c(theta)), n = muestra, sd = sigma)
```

```
arima.sim(model=list(order=c(0,0,1),ma=c(theta)), n = muestra, sd = sigma)
```

donde:

- $\theta$  es el parámetro del modelo MA(1).
- $n$  es el tamaño de muestra a ser simulado.
- $\sigma_e$  es la desviación del ruido blanco, es decir  $\sigma_e$ .

# Simulación de un modelo MA(1)

## Actividad:

- 1 Simule un modelo MA(1) con  $\theta = 0.9$  y  $\sigma_{\epsilon}^2 = 4$
- 2 Compare la función media teórica y muestral.
- 3 Compare la función de varianza teórica y muestral.
- 4 Compare la función de autocorrelación teórica y muestral.
- 5 Compare la función de autocorrelación parcial teórica y muestral.
- 6 Repita este procedimiento para otros valores de  $\phi$  y  $\sigma_e$

# Propiedades del modelo MA(1)

- Un modelo MA(1) siempre es estacionario.
- Un modelo MA(1) es invertible si  $|\theta| < 1$  (que el modelo no sea explosivo).

# Modelo MA(2)

- El modelo de medias móviles de orden 2 se define como:

$$Y_t = \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2}$$

$$Y_t = \theta(B)\epsilon_t$$

donde  $\theta(B) = 1 - \theta_1 B - \theta_2 B^2$  es el polinomio de medias móviles.

# Parámetros del modelo MA(2)

Media, varianza y autocovarianza

- Función media:

$$E(Y_t) = E(\epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2}) = 0$$

- Función varianza: puede demostrarse que:

$$V(Y_t) = \gamma_0 = (1 + \theta_1^2 + \theta_2^2)\sigma_e^2$$

- Función de autocovarianza: distinta de cero para  $k = 1, 2$ :

$$\gamma_k = \begin{cases} (-\theta_1 + \theta_1\theta_2)\sigma_e^2 & k=1 \\ -\theta_2\sigma_e^2 & k=2 \\ 0 & k=3, \dots \end{cases}$$



# Parámetros del modelo MA(2)

## Autocorrelación y autocovarianza

- Función de autocorrelación: se corta luego del periodo  $q$ :

$$\rho_k = \begin{cases} \frac{-\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2} & sik=1 \\ \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2} & sik=2 \\ 0 & sik=3, \dots \end{cases}$$

- Función de autocorrelación parcial:  $\rho_{kk}$  se extingue de manera exponencial amortiguada.

# Simulación de un modelo MA(2)

Código en 

Para simular un MA(2):

```
arima.sim(model=list(ma=c(theta1,theta2)), n = muestra, sd = sigma)
```


```
arima.sim(model=list(order=c(0,0,2),ma=c(theta1,theta2)),  
n = muestra, sd = sigma)
```

donde:

- theta1 y theta2 son los parámetros del modelo MA(2).
- muestra es el tamaño de muestra a ser simulado.
- sigma es la desviación del ruido blanco, es decir  $\sigma_e$ .

# Simulación y propiedades del modelo MA(2)

## Actividad:

- 1 Investigue acerca de los patrones de las funciones de autocorrelación simple y parcial en un modelo MA(2)
- 2 Simule modelos MA(2) que permitan identificar los patrones investigados. Recuerde la inversión del signo en 
- 3 ¿Bajo qué condiciones un modelo MA(2) es estacionario?
- 4 ¿Bajo qué condiciones un modelo MA(2) es invertible?

# Modelo MA(q)

$$Y_t = \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \dots - \theta_q \epsilon_{t-q}$$

- Función media

$$\mu = 0$$

- Función varianza

$$\gamma_0 = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma_e^2$$

- Función de autocovarianza

$$\gamma_k = (-\theta_k + \theta_1 \theta_{k+1} + \theta_2 \theta_{k+2} + \dots + \theta_{q-k} \theta_k) \sigma_e^2 \quad k = 1, \dots, q$$

$$\gamma_k = 0 \quad k > q$$

- Función de autocorrelación

$$\rho_k = \frac{-\theta_k + \theta_1 \theta_{k+1} + \theta_2 \theta_{k+2} + \dots + \theta_{q-k} \theta_k}{1 + \theta_1^2 + \dots + \theta_q^2} \quad k = 1, \dots, q$$

$$\rho_k = 0 \quad k > q$$

- Función de autocorrelación parcial: se extingue

# Modelo ARMA(p,q)

- El modelo de autorregresivo de media móvil de orden  $(p, q)$  se define como:

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

- Un modelo ARMA(p,0) es equivalente a un AR(p)
- Un modelo ARMA(0,q) es equivalente a un MA(q)
- El modelo ARMA suele ser más parsimonioso que AR o MA.

# Modelo ARMA(1,1)

- El modelo de autorregresivo de media móvil de orden (1, 1) se define como:

$$Y_t = \phi Y_{t-1} + \epsilon_t - \theta \epsilon_{t-1}$$

# Parámetros del modelo ARMA(1,1)

Media, varianza y función de autocovarianza

- Función media

$$E(Y_t) = 0$$

- Función varianza:

$$V(Y_t) = \gamma_0 = \frac{1 + \theta^2 - 2\theta\phi}{1 - \phi^2} \sigma_e^2$$

- Función de autocovarianza:

$$\gamma_k = \begin{cases} \phi\gamma_0 - \theta\sigma_e^2 & \text{si } k=1 \\ \theta^{k-1}\gamma_1 & \text{si } k=2,3,\dots \end{cases}$$

# Parámetros del modelo ARMA(1,1)

## Función de autocorrelación y autocorrelación parcial

- Función de autocorrelación:

$$\rho_k = \begin{cases} 1 & sik=0 \\ \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta} & sik=1 \\ \phi^{k-1}\rho_1 & sik=2,3,4,\dots \end{cases}$$

- Función de autocorrelación parcial, va decreciendo exponencialmente.



# Parámetros del modelo ARMA(1,1)

## Propiedades del modelo

- El proceso es estacionario si  $|\theta| < 1$
- El proceso es invertible si  $|\phi| < 1$

# Simulación de un ARMA(1,1)

Código en 

Para simular un ARMA(1,1):

```
arima.sim(model=list(ar=c(phi),ma=c(theta)), n = muestra, sd = sigma)
```

```
arima.sim(model=list(order=c(1,0,1), ar=c(phi),ma=c(theta)),  
n = muestra, sd = sigma)
```

donde:

- $\phi$  es el parámetro del componente AR(1).
- $\theta$  es el parámetro del componente MA(1).
- *muestra* es el tamaño de muestra a ser simulado.
- $\sigma$  es la desviación del ruido blanco, es decir  $\sigma_e$

# Modelo ARIMA

## Definición

Una serie de tiempo  $Y_1, \dots, Y_n$  sigue un proceso ARIMA(p,d,q) si su d-ésima diferencia es un proceso ARMA(p,q). Se puede definir la relación:

$$Z_t = (1 - B)^d Y_t$$

donde  $Z_t$  sigue un ARMA(p,q) y  $Y_t$  un ARIMA(p,d,q). Entonces, la relación de ARMA

$$\phi_p(B)Z_t = \theta_q(B)\epsilon_t$$

es llevada a ARIMA para la serie de tiempo original (Y):

$$\phi_p(B)(1 - B)^d Y_t = \theta_q(B)\epsilon_t$$

# Simulación de un ARIMA(1,d,1)

Código en 

Para simular un ARIMA(1,d,1):

```
arima.sim(model=list(order=c(1,d,1), ar=c(phi),ma=c(theta)),  
n = muestra, sd = sigma)
```

donde:

- $d$  es el número de diferenciaciones que debe realizarse para conseguir estacionariedad en la serie.
- $\phi$  es el parámetro del componente AR(1).
- $\theta$  es el parámetro del componente MA(1).
- $muestra$  es el tamaño de muestra a ser simulado.
- $\sigma$  es la desviación del ruido blanco, es decir  $\sigma_e$

# Modelo ARIMA

## Modelamiento

- 1 La serie debe diferenciarse  $d$  veces, hasta que se consiga estacionariedad. Generalmente  $d = 0$ ,  $d = 1$  o  $d = 2$ .
- 2 Analizar las funciones de autocorrelación y autocorrelación parcial a fin de dar valores tentativos para  $p$  (AR) y  $q$  (MA).
- 3 Estimar los parámetros del o de los modelos tentativos.
- 4 En caso sea más de 1 (es lo usual), comparar los modelos.
- 5 Pronosticar para el horizonte  $h$  deseado.

# Estacionalidad

- La estacionalidad ocasiona fuerte asociación entre retardos de orden  $s$
- Se definen los operadores de diferencia y retardo estacional  $\Delta^s$  y  $B^s$ , respectivamente:

$$\Delta^s y_t = y_t - y_{t-s}$$

$$B^s y_t = y_{t-s} \quad (B^s)^n y_t = y_{t-sn}$$

$$\Delta^s y_t = (1 - B^s) y_t$$

- Recordar que:

$$(\Delta)^s \neq \Delta^s$$

$$(\Delta)^s = (1 - B)^s \quad \Delta^s = 1 - B^s$$

- Tal como la diferencia simple, la estacional también puede llevarse a cabo  $D$  veces:

$$(\Delta^s)^D y_t = (1 - B^s)^D y_t$$



# Modelo SARIMA

Una serie de tiempo  $Y_1, \dots, Y_n$  sigue un proceso  $\text{ARIMA}(p,d,q) \times (P,D,Q)_s$  si su  $d$ -ésima diferencia simple y  $D$ -ésima diferencia estacional es un proceso  $\text{ARMA}(p,q)$ . Se puede definir la relación:

$$Z_t = (1 - B)^d (1 - B^s)^D Y_t$$

donde  $Z_t$  sigue un  $\text{ARMA}(p,1)$  y  $Y_t$  un  $\text{SARIMA}(p,d,q) \times (P,D,Q)_s$ . Entonces:

$$\phi_p(B) \Phi_P(B^s) (1 - B)^d (1 - B^s)^D Y_t = \theta_q(B) \Theta_Q(B^s) \epsilon_t$$

por ejemplo, un modelo  $\text{ARIMA}$  con valores  $s = 12$ ,  $p = d = Q = 0$  y  $P = q = D = 1$ :

$$\Phi_1(B^{12})(1 - B^{12})Y_t = \theta_1(B)\epsilon_t$$

$$(1 - \Phi_1 B^{12})(1 - B^{12})Y_t = (1 - \theta_1 B)\epsilon_t$$

al ser expresado por extenso:

$$Y_t = (1 + \Phi)Y_{t-12} - \Phi Y_{t-24} + \epsilon_t - \theta \epsilon_{t-1}$$



# Bibliografía

- Bowerman, B; O'Connell, R; Koehler, A. Pronósticos, series de tiempo y regresión, un enfoque aplicado. Cengage Learning, 4ta edición. México, 2006.
- Cryer, J; Chan, K. Time Series Analysis With Applications in R. Springer, 2da edición. EEUU. 2008.
- Court, E; William, E. Estadísticas y Econometría Financiera. Cengage Learning. 1ra edición. Argentina, 2011.
- Cowpertwait, P; Metcalfe, A. Introductory Time Series with R. Springer. EEUU, 2009
- Hanke, J; Reitsch, A. Pronósticos en los negocios. Prentice Hall, 5ta edición. México. 1996.
- Morettin, P; Toloi, C. Análise de séries temporais. Editora Blucher, 2da edición. Brasil, 2006.